

ROGJ 2025/26

Tema 12

Učenje akustičkih
modela govora za
raspoznavanje
zvuka

Deepspeech2 kao alat za raspoznavanje govora

**Baza govora → priprema podataka →
treniranje modela → testiranje**

LUKA IVANIĆ

02 · Skup podataka

LibriSpeech: baza snimljenog i transkribiranog govora

Što je u bazi?

Engleski čitani govor iz LibriVox audioknjiga + transkripti iz teksta knjiga.

Službeno: oko 1000 h, 16 kHz, segmentirano i poravnano;
licenca CC BY 4.0.

Službene podjele i naš subset

Dostupno: train-clean-100, train-clean-360, train-other-500,
dev-clean, dev-other, test-clean, test-other.

Preuzeto lokalno: train-clean-100, dev-clean i test-clean.

Clean / other

WSJ si-84 akustički model + book-specific bigram LM prepoznali su audio; WER se računa protiv transkripta iz knjige.

Niži WER govornici → clean; viši WER govornici → other.

train

100.6 h / 28539 / 251

dev

5.4 h / 2703 / 40

test

5.4 h / 2620 / 40

ukupno

111.4 h / 33862 / 331

trajanje / broj izgovora / broj govornika

Transkripta -> JSONL baza

Struktura: <subset>/<speaker_id>/<chapter_id>/

Audio: .flac · transkript:

<speaker_id>-<chapter_id>.trans.txt

Redak: utterance_id TRANSCRIPT TEXT, npr.

2412-153954-0000 ...

Konverzija: jedna izgovorena rečenica → jedan JSONL red.

Polja: audio_filepath, duration, text, source_split,
speaker_id, chapter_id, utterance_id.

03 · Alatni lanac

PaddlePaddle + PaddleSpeech

PaddlePaddle + PaddleSpeech: alatni lanac za ASR

PaddlePaddle = framework · PaddleSpeech = speech toolkit · DeepSpeech2 = ASR model

PaddlePaddle

PArallel Distributed Deep Learning.

Open-source framework za duboko učenje, u ulozi sličnoj PyTorchu ili TensorFlowu. Daje tenzore, slojeve, treniranje, inferenciju i CPU/GPU izvršavanje.

PaddleSpeech

Open-source speech/audio toolkit izgrađen na PaddlePaddleu.

Nije samo kolekcija modela: podržava pripremu, treniranje, korištenje, dekodiranje i testiranje govornih modela. Kao HuggingFace Transformers analogija, ali fokusirano na govor i audio.

Za projekt

Koristimo ekosustav oko DeepSpeech2: LibriSpeech priprema, trening akustičkog modela i testiranje.

ASR arhitekture u PaddleSpeechu: DeepSpeech2, Transformer, Conformer.

Projekt

LibriSpeech


značajke govora

DeepSpeech2
trening

dekodiranje

CER/WER

DeepSpeech2: arhitektura neuronske mreže



1  **Audio → STFT/FFT → spektrogram**
ulaz su audio značajke; cilj je transkript

2  **Konvolucija**
isti filter traži lokalne obrasce kroz vrijeme/frekvenciju

3  **GRU/RNN**
bidirectional slojevi koriste prošli i budući kontekst

4  **CTC**
uči bez timestampova za svaki znak; blank + ponavljanja se sažimaju u tekst



audio



značajke



kontekst



znakovi po frameu



transkript

05 · Paper baseline

DeepSpeech2 u radu: referentna skala i rezultati

End-to-end ASR: spektrogram → conv/RNN → vjerojatnosti znakova → CTC + beam search → transkripcija.

Što su trenirali: 11-slojni ENG DS2 = 3×2D conv + 7 bidirekcijskih RNN + FC.
BatchNorm + SortaGrad; CTC + beam search + LM; bigram output, stride 3.
Finalno: ~100M simple-RNN model za engleske rezultate.
Ispitano: 1-3 conv sloja, 1-7 RNN/GRU slojeva, 1D/2D conv, stride i veličina modela.

Podaci: 11,940h ENG podataka, oko 28% public / 72% Baidu internal.
Trening: SGD + Nesterov, momentum 0.99, minibatch 512, clip 400.
LR [1e-4, 6e-4] / 1.2 po epohi; do 20 epoha.
Decode/aug/compute: beam 500, 5-gram KenLM, šum; 8-16 GPU, 3-5 dana.

Table 1 · dubina arhitekture (~38M parametara)

Architecture	Hidden	Base WER	BN WER
1 RNN, 5 total	2400	13.55	14.40
3 RNN, 5 total	1880	11.61	10.56
5 RNN, 7 total	1510	10.77	9.78
7 RNN, 9 total	1280	10.83	9.52

Table 10 · količina podataka (68M model)

Data	Hours	Regular	Noisy
1%	120	29.23	50.97
10%	1200	13.80	22.99
20%	2400	11.65	20.41
50%	6000	9.51	15.90
100%	12000	8.46	13.59

Table 11 · veličina modela

Size	Type	Regular	Noisy
18M	GRU	10.59	21.38
38M	GRU	9.06	17.07
70M	GRU	8.54	15.98
70M	RNN	8.44	15.09
100M	GRU	7.78	14.17
100M	RNN	7.73	13.06

Table 13 · LibriSpeech rezultati

Test set	DS1	DS2	Human
test-clean	7.89	5.33	5.83
test-other	21.74	13.25	12.69

06 · Plan izvedbe

Plan izvedbe projekta

Cilj: reproducirati DeepSpeech2 pristup na javnom LibriSpeech skupu.

Istrenirati akustički model, dekodirati govor u tekst i izmjeriti kvalitetu pomoću WER/CER.

Od podataka do evaluacije

LibriSpeech → DeepSpeech2/PaddleSpeech → Mac mini trening → optimizacija ili H200 fallback → WER/CER

1. LibriSpeech

train-clean-100 prvo
dev/test: test-clean
po mogućnosti test-other

2. Model + alati

DeepSpeech2 u PaddleSpeechu
spektrogrami, CTC
beam search, opcionalni LM

3. Prvi trening

Mac mini lokalno
paper-style hiperparametri
gdje je izvedivo

4. Ako je presporo

Apple Silicon optimizacije
manji model
manji podatkovni subset

Mac-mini prespor?

Ako Mac mini i optimizacije nisu dovoljni: cloud GPU, npr. NVIDIA H200.

Ako resursi dopuste: proširiti trening iz train-clean-100 prema većim LibriSpeech splitovima.

Evaluacija i prikaz

Mjerimo WER i CER na dev/test splitovima.

Uspoređujemo predikcije s referentnim transkriptima i prikazujemo konkretne pogreške.

Očekivani rezultati: manifesti · checkpointi · dekodiranje · WER/CER rezultati.

Analiza utjecaja modela, podataka i hardvera.

THE END

Hvala na pažnji

Pitanja?